

PROYECTO FINAL

Gestión de Datos · Data Management

Construcción de un Entorno Analítico y Cálculo de Métricas Relacionadas con el Cliente

Autor

Álvaro Santamaría Antón

Universidad Alfonso X el Sabio

Curso 2025/2026

RESUMEN EJECUTIVO

Se ha construido un entorno analítico end-to-end sobre una base de datos operacional de venta de productos de salud (17 tablas, 42.555 líneas de venta, 6 años). El pipeline ETL automatizado carga un Data Warehouse en estrella (6 dimensiones + 2 hechos) en **19 segundos** con **21/21 validaciones automáticas en verde**. Sobre el DWH se calculan tres versiones del CLTV, scoring RFM y Churn Risk, y un clustering K-Means tras PCA que segmenta a 5.750 clientes en 4 perfiles operativos. **Conclusión clave:** el 13% de la base (clusters Champions) genera el 91,7% del valor histórico de la empresa.

1. Contexto del proyecto y arquitectura

1.1 Modelo de negocio y reto analítico

El caso de uso corresponde a una empresa de venta retail de 50 productos de salud distribuidos a través de **20 tiendas** desde **1 almacén central**. El histórico cubre 6 años completos (2020-2025) con 5.750 clientes únicos, 20.000 ventas y 42.555 líneas. Los datos están dispersos en varios sistemas operacionales (ERP, CRM, postventa) y la empresa carece de una vista consolidada para tomar decisiones estratégicas. El reto es **diseñar e implementar un entorno analítico centralizado que habilite el cálculo del Customer Lifetime Value (CLTV) y la segmentación accionable de clientes**.

1.2 Arquitectura técnica

Se ha implementado una arquitectura por capas siguiendo las buenas prácticas de Kimball, separando origen, staging y modelo dimensional para garantizar idempotencia, trazabilidad y reproducibilidad:

ORIGEN <i>saleshealth_origen</i> BD operacional 17 tablas, public	STAGING <i>stg.*</i> Copia tal cual Aísla origen, debug	DWH <i>dwh.*</i> Estrella + copo 6 dim + 2 fact	MARTS <i>marts.customer_360</i> CLTV + RFM Clustering K-Means
---	---	---	---

Figura 1. Arquitectura por capas del flujo de datos. Las flechas implícitas van de izquierda a derecha.

1.3 Stack tecnológico

Capa	Tecnologías y librerías
Persistencia	PostgreSQL 18 (origen y DWH separados)
ETL / Pipeline	Python 3 · pandas · SQLAlchemy · psycpg2 · python-dotenv (logging propio + pushdown SQL)
Analítica / ML	scikit-learn (StandardScaler, PCA, KMeans, Silhouette) · matplotlib · seaborn
Modelado / Diagramas	pgAdmin ERD · dbdiagram.io (DBML versionado en repo)
Versionado / Repo	Git + GitHub (público) · estructura modular en paquetes Python

1.4 Pipeline ETL automatizado

El pipeline se ejecuta con un único comando ***python -m etl.run_etl*** y orquesta 6 fases secuenciales: (1) Extract a staging, (2) Transform+Load de dimensiones, (3) Transform+Load de hechos, (4) Validaciones, (5) Construcción de customer_360 con CLTV+RFM+Churn, (6) PCA+Clustering. Tiempo total medido: **19,34 segundos** sobre PostgreSQL local. Idempotente: cada ejecución hace TRUNCATE+INSERT, lo que permite recargas sin estado residual.

3. Hallazgos del EDA y decisiones de diseño

3.1 Inventario y volúmenes

Tabla	Filas	Observación
sale_item	42.555	Grano más fino - base del fact_sales
sale	20.000	Cabeceras de venta (2,1 items/venta de media)
customer	5.750	87% one-shot, 13% recurrentes (≥2 compras)
return_item	2.330	5,32% de tasa de devolución a nivel item
product	50	1 producto sin record en central_product (decisión \$3.3)

3.2 Calidad del dato — validaciones de coherencia

Se realizaron tres validaciones críticas a nivel item: (1) cobertura temporal (todas las fechas de venta y devolución encajan con dim_date, 0 huérfanos), (2) coherencia subtotal = quantity × unit_price (42.547/42.555 OK; los 8 desvíos coinciden exactamente con los items con oferta), (3) coherencia sale.total = SUM(items): **19.999/20.000 OK**. Una única anomalía detectada (sale_id 13.009, +3,00€) se decide **recalcular total desde items en el ETL** (los items son la fuente de verdad).

3.3 Decisiones de diseño documentadas

Hallazgo	Decisión adoptada
Producto 29 sin coste en central_product (711 ventas, 1.426 unidades)	Imputar unit_cost = 0,60 × precio (margen 40% como el resto). Marcar is_cost_imputed=TRUE para trazabilidad. Mantener flag en fact_sales y dim_product.
city_zone sin FK declarada	Enlace por postal_code con store (20/20 OK). Geografía solo aplica a tienda; cliente sin dato geográfico.
return_reason sin FK declarada	Resuelto por reason_id (0 huérfanos). Motivo 6 'Desconocida' nunca usado pero se conserva por completitud.
Devoluciones: ¿hecho propio o solo flag?	Ambos: fact_returns como hecho secundario + flag is_returned en fact_sales (optimización analítica para CLTV neto).
Anomalía sale_id 13009 (+3€)	Recálculo determinista: net_revenue del fact = SUM(item.subtotal). Anomalía documentada en log.

3.4 Patrones temporales y de cliente




Figura 4. Evolución mensual de ventas e ingresos. Datos cubren 6 años completos (2020–2025); se detecta un cambio de patrón a partir de Q3 2025 (mayor volumen, ticket medio inferior).

4. ETL: pipeline reproducible y validado

4.1 Diseño del pipeline

El ETL está implementado como un paquete Python modular (*etl/*) con responsabilidad única por archivo: *extract.py* (origen → stg), *transform_dimensions.py* (carga las 6 dimensiones), *transform_facts.py* (carga los 2 hechos vía INSERT...SELECT con pushdown a Postgres), *validate.py* (21 validaciones declarativas), *build_customer_360.py* y *build_clusters.py*. Un orquestador *run_etl.py* los encadena. Logging unificado con archivo persistente por ejecución y timestamp en *etl/logs/*.

4.2 Métricas tras la carga (datos reales)

Métrica	Valor
Líneas de venta cargadas	42.555
Ingresos totales (net_revenue)	9.678.678,67 €
Coste agregado	5.806.999,39 €
Margen bruto histórico	3.871.679,28 € (40,00%)
Items devueltos / Margen perdido por devoluciones	2.264 items · 110.531,16 €
Items con coste imputado (producto 29)	711 (1,67%)
Tiempo total pipeline end-to-end	19,34 s

4.3 Validaciones automáticas (21/21 PASS)

Categoría	# Tests	Cobertura
row_count	8	Cardinalidad esperada en cada dim/fact frente a expected_count
fk_integrity	5	Cero huérfanos en cada FK (customer/product/store/date) y fact_returns→fact_sales
business	6	Coherencia origen ↔ DWH (revenue, quantity), gross-discount=net, days_to_return≥0, no NULLs en métricas
decisions	2	Imputación de coste solo aplica al producto 29; el producto 29 siempre tiene flag activo

Resultado: **21/21 PASS, 0 FAIL, 0 ERROR** · tiempo de validación 0,10 s. Las validaciones forman parte del orquestador y abortan el pipeline si alguna falla, garantizando que el DWH nunca queda en estado inconsistente.

5. Métricas de cliente: CLTV (3 versiones)

5.1 Planteamiento metodológico

La fórmula del enunciado $CLTV = Ingresos \times Margen \times Frecuencia \times R(t)$ presenta dos limitaciones conceptuales: (a) la multiplicación de Ingresos por Frecuencia duplica un factor (los ingresos ya incorporan la frecuencia), (b) $R(t)$ no está definido. Para mitigar este problema y aportar valor analítico, el proyecto calcula **tres versiones complementarias del CLTV**:

Versión A — CLTV histórico (basado 100% en datos reales)

$CLTV_{hist} = SUM(net_revenue) - SUM(refunds) - SUM(cost_amount)$ = margen neto realmente generado por el cliente hasta hoy. Es la métrica más fiable y la que se usa como variable objetivo en el clustering.

Versión B — CLTV predictivo (proyección a 3 años, solo recurrentes)

$CLTV_{pred} = avg_order_value \times margen\% \times frecuencia_anual \times 3$ Solo aplicable a los 750 clientes con ≥ 2 compras (en los one-shot la frecuencia/lifespan son indeterminados).

Versión C — CLTV literal del enunciado

$CLTV_{form} = net_revenue \times margen\% \times frecuencia_anual \times 3 \text{ años}$. Calculada para cumplir la rúbrica; se utiliza con cautela porque los valores son inflados por el doble conteo de la frecuencia.

5.2 Distribución del CLTV histórico




Figura 5. Distribución bimodal del CLTV histórico. Izquierda: todos los clientes (mediana 52€, dominada por one-shot). Derecha: solo recurrentes (n=750, mediana ~4.500€, distribución unimodal cercana a normal).

5.3 Pareto extremo — concentración del valor




Figura 6. Curva de Pareto del CLTV histórico.

Top % clientes	Nº clientes	% CLTV total	Lectura estratégica
Top 1%	57	10,9 %	Núcleo VIP
Top 5%	287	44,7 %	Champions estables
Top 10%	575	77,6 %	Foco de retención
Top 20%	1.150	94,1 %	Casi todo el valor

6. RFM Score y Churn Risk

6.1 RFM Score (Recency · Frequency · Monetary)

Cada cliente recibe un score de 1 a 5 en cada dimensión (quintiles), construido sobre *days_since_last_order* (R, invertido), *num_orders* (F) y *net_revenue_after_returns* (M). La regla de segmentación combina los tres scores en 9 segmentos accionables (Champions, Loyal, At Risk, Lost, etc.) según las prácticas estándar del retail.




Figura 7. Distribución de clientes por segmento RFM y CLTV histórico medio asociado.

Segmento RFM	Nº	% base	CLTV total	% CLTV
Champions	833	14,5 %	3.352.756 €	89,1 %
Loyal Customers	333	5,8 %	152.999 €	4,1 %
New Customers	975	17,0 %	62.637 €	1,7 %
Resto (6 segmentos)	3.609	62,7 %	192.700 €	5,1 %

6.2 Churn Risk Score y validación cruzada

Score continuo (0–1) construido como combinación ponderada de la recency normalizada (peso 0,7) y la frecuencia normalizada inversa (peso 0,3). Discretizado en 3 niveles (Low/Medium/High). El umbral de churn binario se fija en **365 días sin compra** respecto al snapshot date (último día con datos: 2025-12-30). La validación cruzada con el flag binario *is_churned* confirma la coherencia del modelo:




Figura 8. Cross-tab *is_churned* × *churn_risk_level*. 0 active con risk High (sin falsos positivos extremos); 318 active con Medium = lista de pre-churn accionable.

7. PCA y clustering K-Means

7.1 Preparación de features y reducción dimensional

Se seleccionan 8 variables que cubren las 4 dimensiones del comportamiento del cliente (volumen, valor, temporalidad, calidad post-venta), evitando colinealidades obvias: *num_orders*, *total_units*, *avg_order_value*, *net_revenue_after_returns*, *gross_margin*, *customer_lifespan_days*, *days_since_last_order*, *return_rate*. Escalado con StandardScaler (media 0, varianza 1). PCA con todas las componentes: **PC1 explica el 70,3 % de la varianza** (índice global de actividad: cargas ~0,42 en todas las variables económicas), PC1+PC2 alcanzan el 82,7 % (PC2 captura el *return_rate*, carga 1,00). Para el clustering se usan las componentes hasta superar el 80 % de varianza acumulada (2 componentes en el modelo global, 3 en el de recurrentes).




Figura 9. Scree plot del PCA sobre los 5.750 clientes — varianza explicada y acumulada.

7.2 Selección de K

Combinación de método del codo (inercia/WCSS) y silhouette score sobre $K \in [2,10]$. En el modelo global $K=4$ mantiene un silhouette excelente (**0,831**) y separa un cluster de devolvedores que ni $K=2$ ni $K=3$ distinguen. En el modelo de recurrentes $K=4$ se justifica también por interpretabilidad operativa (los silhouette son menores, ~0,26, pero la población es intrínsecamente más homogénea).




Figura 10. Método del codo (izquierda) y silhouette (derecha) para K-Means sobre todos los clientes.

7.3 Caracterización de clusters (modelo global, $K=4$)

Cluster	Nº	CLTV avg	CLTV total	Orders	Return %
Champions Premium	387	5.548 €	2.147.240 €	22,9	2,5 %
Champions activos	363	3.590 €	1.303.057 €	16,9	2,5 %
Compradores ocasionales	4.580	67 €	305.609 €	1,0	0,1 %
Devolvedores compulsivos	420	12 €	5.242 €	1,0	88,0 %

Hallazgo clave: el cluster ‘Devolvedores compulsivos’ (420 clientes, 7,3% de la base) tiene un return rate del 88,0% y aporta apenas 5.242 € de CLTV. Es un segmento **operacionalmente tóxico** que el RFM tradicional *no detecta* — solo el clustering multidimensional lo aísla.

8. Insights estratégicos y recomendaciones

8.1 Sub-segmentación de clientes recurrentes (n=750)

Sobre la población de recurrentes se aplica un segundo K-Means que identifica 4 perfiles de mayor granularidad: **Élite VIP (173 clientes, CLTV 6.299€)**, **Recurrentes Consolidados (293, 4.741€)**, **Recurrentes Estándar (192, 3.302€)** y **Recurrentes En Riesgo (92, 3.668€ pero con 349 días sin compra)**. Este último cluster — 92 clientes con CLTV alto pero recencia anómala — constituye una **lista accionable de oro**: son Champions desconectándose. Una campaña de retención sobre ellos protegería ~338.000 € de CLTV potencial.




Figura 11. Clusters sobre clientes recurrentes (K=4) — proyección 2D sobre PC1×PC2.

8.2 Conclusiones estratégicas

- **Concentración del valor:** el 13% de la base (clusters Champions Premium + activos = 750 clientes) genera 3,45 M€ de los 3,76 M€ de CLTV histórico (91,7 %). Toda la estrategia de retención debe pivotar sobre estos 750 clientes.
- **Detección de toxicidad:** el clustering revela 420 clientes con un return rate del 88 % que son invisibles en el análisis RFM. Acción: investigar patrón (posible arbitraje), implementar restricciones operativas tras N devoluciones.
- **Lista de pre-churn accionable:** 92 Champions 'En Riesgo' con 349 días sin compra y CLTV >3.000 €. ROI de campañas dirigidas muy alto frente a captación nueva.
- **Activación de one-shot:** 5.000 clientes one-shot (87 %) aportan solo el 8 % del CLTV. Convertirlos en recurrentes (~2 compras) duplicaría su CLTV individual; ventana de oportunidad si la 2ª compra ocurre en los primeros 6 meses.
- **Margen estable al 40 %:** uniformidad entre las 6 categorías sugiere política de precios alineada. El margen no es un diferenciador entre productos; el upside está en frecuencia y ticket medio.

9. Reproducibilidad y cierre

9.1 Estructura del repositorio

Repositorio Git público con la siguiente estructura modular (resumida):

Carpeta / Archivo	Contenido
etl/	Paquete Python: extract, transform_dimensions, transform_facts, validate, build_customer_360, build_clusters, run_etl (orquestador), config, db, logger
sql/ddl/	DDL versionado: dimensiones, hechos, customer_360 y columnas de cluster
notebooks/	Análisis exploratorio reproducible: inventario, EDA, CLTV, clustering
docs/diagramas/	ER de origen, modelo dimensional (PNG/PDF/DBML)
reports/figures/	18 figuras generadas por los notebooks (versionadas para uso en docs)
.env.example, requirements.txt, README.md	Plantilla de credenciales, dependencias bloqueadas y guía de replicación

9.2 Replicación en otra máquina

- 1. `git clone <repo>`, `python -m venv venv`, activación, `pip install -r requirements.txt`.
- 2. Crear las dos BD en PostgreSQL (saleshealth_origen, saleshealth_dwh) y restaurar el dump de origen con `pg_restore`.
- 3. Copiar `.env.example` a `.env` y rellenar credenciales.
- 4. Ejecutar los 4 DDL sobre saleshealth_dwh y lanzar `python -m etl.run_etl`. Tiempo total ~20 segundos.

9.3 Posibles mejoras

- Implementar **SCD Type 2** en `dim_customer` y `dim_product` para preservar histórico de cambios (precios, atributos cliente).
- Carga incremental** basada en `created_at/updated_at` en origen, evitando el truncate completo en producción.
- Modelo predictivo de churn** supervisado (logistic regression / gradient boosting) con churn binario como target, usando `customer_360` como feature store.
- Orquestación con Airflow/Prefect** para programar el pipeline diariamente y monitorizar SLA.
- Dashboard interactivo** (Streamlit) para consumo por equipos de marketing — entregado como anexo del proyecto.

9.4 Resultado final del proyecto

✓ DWH dimensional reproducible (8 tablas, 21 validaciones automáticas) • ✓ Pipeline ETL en 19 s end-to-end • ✓ 5.750 clientes con CLTV (3 versiones), RFM y Churn Risk • ✓ Clustering K-Means tras PCA con 4 segmentos accionables • ✓ Insights de negocio cuantificados y trazables.

9.5 Referencias

Business Research Insights (2024). *Health and Wellness Products Market Report — 2026 to 2035*. <https://www.businessresearchinsights.com/es/market-reports/health-and-wellness-products-market-118977>

Putler (2024). *14 Customer Retention Metrics & KPIs to Track (With Formulas)*.

ProsperStack (2024). *28 Customer Retention Metric Formulas for Business Success*.

Kimball, R. & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3ª ed.). Wiley.